

在线二部匹配中预测的局限性：一项统一实验研究

[作者姓名] ——硕士学位论文（草稿）

摘要

面向在线二部匹配的学习增强（带预测）算法近年大量涌现：MinPredictedDegree 消费一个逐节点的度数预测，而一族“测试-回退”（test-and-fallback）方案则在提交“跟随预测”或“回退到免预测基线”之前，先在亚线性长度的到达前缀上对类型直方图预测进行检验。这些算法此前均被孤立地研究。本文给出首个统一实验研究，将它们置于同一套评测框架下——采用共同的结构化预测误差模型、共同的最优解、以及置信区间——并跨越合成图、六个真实世界图与真实请求 trace 进行比较。我们的核心发现是：在平均情况输入上，预测的价值是鲁棒性保险，而非性能杠杆——免预测基线本已近乎最优，好建议的一致性上升空间很小；而无防护地跟随预测在坏预测下会崩到远低于基线，成熟算法的实际价值恰恰在于它们从不如此。本文以一个理论展望收束：一条已证明的一致性/鲁棒性权衡不等式，加上对实验的一种预算-赌注解读——判定是否信任建议所需的前缀按建议上升空间的平方反比增长，而在强基线的平均情况输入上，这一代价超过实例本身的长度。实验与展望共同给出一句话：在平均情况匹配上，建议的上升空间小于判定其是否可信所需付出的代价。

目录

第一章 引言	2
第二章 背景与相关工作	5
第三章 模型、算法与方法	9
第四章 统一基准	13
第五章 什么支配损失：顺序误差与 ACI 的界	16
第六章 深入研究测试-回退	18
第七章 外部效度	22
第八章 探索方向与负结果	25
第九章 应用案例研究：AI 推理服务	29
第十章 结论与未来工作	32
参考文献	35
附录 A 复现指南	37

第一章 引言

1.1 研究背景与动机

在线二部匹配是不可逆序贯分配的经典模型。离线资源事先已知；请求逐个到达；每个请求必须在看到其余输入之前，立即、不可撤销地被匹配到一个可用的相容资源——或被丢弃。它是在线广告投放、网约车派单、器官交换以及现代服务系统中请求路由背后的抽象。由于决策无法撤销，全部难度都在于在**对未来不确定的情况下做出良好的即时承诺**。

近年一个有影响力的思路是：给这样的算法一个关于输入的**预测**——关于哪些资源会被争用、或每类请求将到达多少的提示——并要求两个保证同时成立：**一致性 (consistency)**，即预测准确时接近最优；以及 **鲁棒性 (robustness)**，即预测错误时不差于一个免预测算法。针对在线匹配，具体出现了两族这样的 **学习增强 (learning-augmented)** 算法：MinPredictedDegree（消费逐资源的度数预测），以及一族 **测试-回退 (test-and-fallback)** 方案（在一段亚线性到达前缀上检验请求类型预测，再决定是否信任它）。

这些算法都带有诱人的最坏情况保证，然而——正如本文将以实验证明的——它们在平均情况下的行为却出奇地平淡：在真实负载上，这些成熟的预测很少真的**带来帮助**，而算法的真正价值在于它们不会**造成损害**。这种“最坏情况承诺”与“平均情况现实”之间的落差，正是本文的出发点。此外，这些算法此前都只被**孤立地**研究——各自在自己的输入模型上、针对自己的预测误差概念、且主要通过理论——因此没有一个共同的基准来比较它们、量化预测究竟带来多少收益、或解释这种落差。本文提供这一共同基准，并最终给出一个解释。

1.2 研究目标

本文围绕三个问题展开：

1. 这些学习增强的在线匹配算法在同一预测误差模型、同一输入下正面比较，究竟表现如何——在真实数据上，预测帮助多少、代价几何？
2. 自适应的测试-回退机制的失效模式是什么——其检验的代价、其接受/拒绝决策的校准、以及它在何处出错？

3. 为什么平均情况的体验与最坏情况的承诺差别如此之大——观察到的这堵墙是特定算法与生成器的产物，还是必然的？

前两个问题通过实验回答；第三个通过理论回答。

1.3 主要贡献

- 一个统一实验基准（第 4 章）：将免预测基线、MinPredictedDegree 及其增强、以及测试-回退算法置于同一套框架——共同的图、共同的结构化预测误差模型、共同的最优解、以及置信区间——这是这些族的首次正面比较。
- 把预测刻画为鲁棒性保险（第 4、7 章）：无防护地跟随预测在坏预测下会崩到低于免预测基线；两种不同机制——结构式（增强算法）与自适应式（测试-回退）——以不同的一致性/鲁棒性取舍恢复了安全性；且在平均情况输入上一致性上升空间很小，因此价值在于下行保护。该图景在合成图、六个真实世界图与真实请求 trace 上得到验证，包括用一个廉价、非机器学习的历史统计预测器。
- 对顺序误差理论的实证性对接（第 5 章）：MinPredictedDegree 的损失由一个 Kendall- τ 顺序误差支配，四种误差模型塌缩到它之上。我们将顺序依赖本身归功于 Aamand-Chen-Indyk 的附录 D，而我们的贡献是刻画已知界的松弛与饱和、以及正确的顺序度量——而非“重新发现顺序重要”。
- 对测试-回退的首个实证研究（第 6 章）：其检验代价、一个阈值校准的病理现象（更准确的检验反而做出更差的决策）、其重校准以及重校准暴露出的分辨率极限、以及对动态组合器的基准评测——后者揭示了一个不可逆惩罚，解释了为何匹配需要先测试再一次性提交（test-then-commit）。
- 对墙为何矗立的量化解释（第 6 章与 10.2 节）：分辨率极限的发现——没有任何实用接受阈值能捕获低于其估计器噪声的上升空间——被证明在整个难度范围上持续成立（图 6.4），并在结论章获得一个理论展望：一条已证明的一致性/鲁棒性权衡不等式，以及一种预算-赌注解读——做出决策所需的前缀按建议上升空间的平方反比增长，恰在基线强处超过实例长度本身。完整的形式化发展被有意留给筹备中的后续工作；除该不等式外，本文不声称任何定理。

除上述之外，本文还记录了（第 8 章）所探索的方向及其返回的负结果——一次试图学习预测器以榨取更多性能的尝试，以及一次试图找到预测真正有帮助的服务场景的尝试——两者都强化了核心发现：它们提出的问题——这堵墙是否被迫？——由结论章的展望（10.2 节）接手。

1.4 论文组织

第 2 章综述背景：在线匹配及其输入模型、学习增强范式、具体的基于预测的匹配算法、以及这些算法的检验背后的分布检验结果。第 3 章固定模型与方法，并通过复现 Borodin 等人研究的一个子集来验证实验框架。第 4 章给出统一基准及其四个发现。第 5 章考察支配（那微小）损失的量——顺序误差

——及其与已知界的关系。第 6 章深入研究测试-回退机制。第 7 章在真实预测器与真实图上检验外部效度。第 8 章报告所探索的方向与负结果。第 9 章给出 AI 推理服务的应用案例研究。第 10 章总结全文：概括发现、给出关于墙为何被迫的理论展望（10.2 节），并讨论局限与未来工作。贯穿全文、先由实验确立、再以展望解释的核心论点可归结为一句话：在平均情况的在线匹配上，预测是鲁棒性保险而非性能杠杆——而其上升空间小于”判定预测是否可信”所需付出的代价。

第二章 背景与相关工作

本章建立全文所依赖的技术背景：在线二部匹配问题及其输入模型（2.1 节）、本文所处的 known-i.i.d. 模型（2.2 节）、学习增强（“带预测”）范式及其一致性/鲁棒性语言（2.3 节）、本文所基准和界定的具体基于预测的匹配算法（2.4 节）、算法的检验与 10.2 节展望背后的分布检验结果（2.5 节），以及本文所填补的文献空白（2.6 节）。

2.1 在线二部匹配与竞争分析

在在线二部匹配中，二部图的一侧——**离线资源**——事先已知，而另一侧的顶点——**在线请求**——逐个到达。每个请求到达时，算法看到其关联的边，必须**立即、不可撤销地**将其匹配到一个当前未匹配的邻居，或不予匹配。目标是最大化匹配的规模（在带权变体中为价值）。性能以**竞争比**衡量，即算法所得匹配与同一输入上的离线最优之间的（期望）比值。

问题的难度完全取决于所假设的**输入模型**：

- **对抗到达序**。请求及其顺序由对手选择。Karp、Vazirani 与 Vazirani 的开创性结果 [1] 表明，随机化的 **Ranking** 算法——预先对资源固定一个均匀随机的优先序，将每个请求匹配到其优先级最高的可用邻居——可达竞争比 $1 - 1/e \approx 0.632$ ，且这在对抗模型下是最优的。确定性算法无法超过 $1/2$ 。
- **随机到达序**。图是对抗的，但请求以均匀随机的顺序到达；这严格易于对抗序，可达高于 $1 - 1/e$ 的比值。
- **Known-i.i.d.**。请求独立同分布地从一个**已知**的请求类型分布中抽取（见 2.2 节）；这是平均情况模型，也是本文所研究的模型。

由于 known-i.i.d. 与随机序模型都比对抗序更温和——形式上 $\text{Known-I.I.D.} \leq \text{Random-Order}$ 在难度上成立——为更难模型设计的算法与保证可以沿用，本文全程使用这一事实。

2.2 Known-i.i.d. 模型

在 known-i.i.d. 模型中, 存在一个二部类型图: 每个在线类型 ℓ 在离线资源中有固定的邻域 $N(\ell)$, 一个实例由从已知分布 p 上独立抽取 m 个到达生成。类型图与 p 已知, 而实现的到达序列未知。它刻画了这样的场景——广告投放、周期性请求流——其中请求的总体在统计上稳定, 尽管单个到达并非如此。

一系列工作将(对类型图取最坏情况的)竞争比推高至 $1 - 1/e$ 对抗壁垒之上: Feldman 等人 [2] 首先通过对一个建议匹配做基于流的蓝/红分解突破了它 (0.67); Manshadi、Oveis Gharan 与 Saberi [3] 及 Jaillet-Lu [4] 用基于 LP 与基于列表的在线策略进一步改进了比值(分别到 ≈ 0.702 与 ≈ 0.729); 后续工作继续精化。这些即是那些以最坏情况最优性为动机的“成熟”算法。

对本文至关重要, 的是, Borodin、Karavasilis 与 Pankratov [5] 对这些算法做了实验研究, 发现在平均情况的 i.i.d. 实例上, 图景与最坏情况大不相同: 简单算法 (Greedy、Ranking) 的表现几乎与成熟算法一样好, 后者的优势是最坏情况而非典型情况的现象。这一“典型输入上简单基线本已近乎最优”的经验观察, 正是本文中心发现的种子, 我们复现其一个子集作为验证 (第 3 章)。

2.3 学习增强算法

算法带预测(或称学习增强)范式(综述见 [6])为一个在线算法配备关于未知输入的预测, 并要求同时给出两个保证:

- **一致性:** 预测准确时接近最优;
- **鲁棒性:** 预测任意错误时不差于一个免预测的保证。

该范式由 Lykouris 与 Vassilvitskii [7] 在竞争缓存中确立, 他们展示了如何在信任与忽略预测器之间插值, 同时对一致性与鲁棒性给出界。随后在滑雪租赁、调度等在线问题上出现了大量文献, 包括 Wei 与 Zhang [8] 关于最优一致性/鲁棒性取舍的分析, 它给出了两目标之间问题固有的 Pareto 前沿。一个反复出现的主题是: 鲁棒性通过对冲获得——将预测器的建议与一个安全默认相结合, 使坏预测无法造成灾难。Chłędowski、Polak、Szabucki 与 Żoła [9] 在一项关于鲁棒学习增强缓存的实验研究中提出的盲从-带切换组合器 (combiner) 即是一种此类对冲机制; 我们将其移植并做基准评测 (第 6 章)。该文也是本文实验半部最接近的方法学模板。近期的理论工作还在分布鲁棒的表述下分析了可达比值如何随预测精度连续退化 [10], 与本文所用的离散一致性/鲁棒性端点互补。

2.4 面向在线二部匹配的预测

两条线索将带预测范式应用于在线匹配, 区别在于它们所消费的预测对象。

度数预测: MinPredictedDegree. Aamand、Chen 与 Indyk [11] 提出 **MinPredictedDegree(MPD)**: 给定对每个离线资源度数(其将被争用的程度)的预测 μ , 将每个到达匹配到其预测度数最小的可用邻居——即保护预测最稀缺的资源。MPD 天生鲁棒: 一个常数(无用)预测器使它退化为 Ranking。一

个关键结构性事实（本文第 5 章将对接）是：MPD 仅通过 μ 诱导的顺序依赖于它；作者的附录 D 用一个顺序量（ $n - \text{LIS}$ ，即真实度数按 μ 排序后不在最长非降子序列中的资源数）为匹配损失定界，并特别表明一个单调（保序）预测导致零损失。

类型直方图建议与测试-回退。第二条线索取预测为类型上的直方图 $\hat{c}$ （各类型将到达多少）。Choo 等人 [12] 提出 **TestAndMatch**：由 $\hat{c}$ 构造一个匹配并模仿（Mimic）它，但先花一段亚线性到达前缀检验观测到的类型频率是否与 $\hat{c}$ 相符——使用一个改编自 Jiao、Han 与 Weissman [13] 的 ℓ_1 -距离检验器——若不符则回退到 Ranking。Burahtep、Erlebach 与 Moses [14] 将其（“Test-and-Match+”）推广到随机到达模型以及对匹配规模的不完全知识。两文均给出上界（算法）；其唯一的下界（Choo 等人的定理 3.1）是一个一般性的对抗不可区分性结果（无算法能既 1-一致又 $> \frac{1}{2}$ -鲁棒），二者都未在随机模型中证明下界。值得注意的是，Choo 等人的接受阈值已经与基线竞争比 β 耦合——但是构造性地、在算法设计内部，而非作为一个下界。该耦合的代价几何——跟随/回退的决策从根本上需要多长的前缀——是本文以实验（第 6 章）与理论展望（10.2 节）接入的问题；完整的形式化发展留给后续工作。

2.5 分布检验

上述算法核心的检验，本质上是分布检验中的一个问题：给定来自未知分布 p （支撑大小为 r ）的样本以及一个已知参照 q ，判定 p 与 q 在 ℓ_1 （全变差）距离上有多远。必须区分两个体制：

- **恒等（非容差）检验**——区分 $p = q$ 与 $\|p - q\|_1 \geq \varepsilon$ ——其样本复杂度为 $\Theta(\sqrt{r}/\varepsilon^2)$ [15, 16]，关于支撑大小是亚线性的。
- **容差检验/距离估计**——区分 $\|p - q\|_1 \leq \varepsilon_1$ 与 $\geq \varepsilon_2$ （ $0 < \varepsilon_1 < \varepsilon_2$ ），即估计距离而非检验相等——可证要难得多：Valiant 与 Valiant [17] 表明它需要 $\Theta(r/\log r)$ 个样本，关于支撑近乎线性。Jiao、Han 与 Weissman [13] 给出了 ℓ_1 -距离估计的匹配界，Canonne、Jain、Kamath 与 Li [18] 精确刻画了整个 $(\varepsilon_1, \varepsilon_2)$ 图景，表明对常数容差，代价跃升到“勉强亚线性”的 $\tilde{\Theta}(r/\log r)$ 。

$\sqrt{r}$ （检验）与 $r/\log r$ （容差检验）之间近乎二次的差距在本文中出现两次。它是 TestAndMatch 的可部署版本退回经验代理的原因，也是该代理在大支撑上失明的原因——即第 6 章测得的分辨率极限。这一壁垒是否也封死其他一切决策规则，比乍看之下微妙得多；结论章的展望（10.2 节）将回到这一点。

2.6 本文的定位

在此背景下，三个空白凸显出来，本文依次填补：

1. **缺乏统一的实证比较。**上述匹配算法各自被孤立地研究，在各自的输入族与误差模型上，且主要通过理论；没有一个在共同框架下的正面实验基准。（第 4-7 章。）
2. **缺乏对测试-回退的实证研究。**[12, 14] 核心的分布检验没有可部署的实现（作者自己也退回到一个经验代理），其检验代价、阈值校准与失效模式未被测量。（第 6 章。）
3. **缺乏对前缀检验代价的量化。**此前无工作测量——或界定——在强基线实例（可捕获上升空间最小之处）上，跟随/回退的决策需要多长的前缀。（第 6 章实证；10.2 节展望。）

本文用实验填补前两个空白，并在第三个上迈出第一步量化的步伐——一个经验分辨率极限加一个理论展望——最终得到一个统一陈述：在平均情况的在线匹配上，预测是鲁棒性保险而非性能杠杆，由跨越合成图、真实图与真实 trace 的实验支撑。

第三章 模型、算法与方法

第 2 章将问题置于其领域中。本章固定全文所用的精确模型与记号 (3.1 节)，详述我们所实现的算法 (3.2 节)、预测对象与结构化误差模型 (3.3 节)、一致性/鲁棒性度量 (3.4 节)，以及实验框架 (3.5 节)。最后，在任何贡献建立于其上之前，通过复现 Borodin 等人已发表的图来验证该框架 (3.6 节)。

3.1 精确的 known-i.i.d. 模型

存在一个包含 n 个离线资源的集合 R ，以及一个含 r 个在线类型的类型图；类型 ℓ 的邻域为 $N(\ell) \subseteq R$ 。一个实例由从类型分布 p 上独立同分布地抽取 m 个到达生成；第 i 个到达揭示其类型（从而其邻域），必须立即、不可撤销地被匹配到其邻域中一个当前未匹配的资源，或不予匹配。类型图与 p 对算法已知，实现的到达序列未知。遵循标准的整型类型约定，默认取 $m = n$ 且 p 均匀，使每个类型的期望计数为整数；经典设定为 $r = n$ （每个离线顶点一个独立类型），而用于直方图建议实验的少类型设定取 $r \ll n$ 。

性能度量为竞争比 $\rho(\text{ALG}) = \mathbb{E}[\|\text{ALG}\|]/\mathbb{E}[\|\text{OPT}\|]$ ，其中 OPT 是实现实例的最大匹配，由 Hopcroft-Karp [19] 精确计算。全文的免预测基线是 KVV Ranking，其比值记为 ρ_{base} （基线强度）。

3.2 算法

所有贪心型算法都是一个原语的实例：给定资源上的一个全序（rank），**GreedyWithPermutation** 将每个到达匹配到其 rank 最小的可用邻居。这使整个算法族成为一条由 rank 参数化的代码路径，这对公平比较与理论都很重要。

- **免预测基线**。SimpleGreedy（恒等 rank）；**Ranking**（均匀随机 rank；基线）；以及随机匹配算法 Feldman 与 Jaillet-Lu，它们通过最大流预计算一个建议匹配——Feldman 经由容量 $\{2, 1, 2\}$ 的流网络及单位流子图的蓝/红分解，Jaillet-Lu 经由容量 $\{3, 2, 3\}$ 的网络得到分数解 $f^* \in \{0, \frac{1}{3}, \frac{2}{3}\}$ 及逐类型的列表分布。每个都有一个非贪婪变体（仅跟随建议）与一个贪婪变体（回退到任意可用邻居）。

- **度数预测。** MinPredictedDegree (MPD) 是按预测度数 $\mu \in \mathbb{R}^R$ 升序排名的 GreedyWithPermutation。常数 μ 给出 Ranking；真实的实现度数给出一致性天花板 (MinDegree)。增强版 Feldman(MPD) 与 JailletLu(MPD) 仅将 MPD 的 rank 用作贪婪回退的平局打破，因此由最坏情况最优的基匹配承担主要负载。
- **类型直方图建议与测试-回退。** 由类型上的计数向量 $\hat{c}$ 我们构造一个建议匹配 $\hat{M}$ ($\hat{c}$ 份拷贝的最大匹配) 并记录其逐类型伙伴。**FollowPrediction** 对每个到达按 $\hat{M}$ 模仿；**TestAndMatch** (Choo 与 BEM 变体) 在长度 k 的前缀上模仿，检验前缀类型频率与 $q = \hat{c}/\|\hat{c}\|_1$ 的经验 ℓ_1 距离是否不超过阈值 τ ，据此继续或回退到 Ranking。我们还移植了 Chłędowski 式动态 **组合器** 作为基准评测对象 (非贡献)。

3.3 预测对象与结构化误差模型

各族消费不同的预测对象——度数向量 μ 与类型直方图 $\hat{c}$ ——因此各以自己的旋钮扰动并在并列的面板中报告。对 μ 我们使用四种结构化误差模型，各返回一个 ℓ_1 幅度与一个归一化的 **Kendall- τ 顺序误差**：随机翻转、系统性偏置 (单调重缩放——保序，故 Kendall- $\tau \equiv 0$ 是构造性的)、对抗 (反射一部分分量)、以及分布漂移 (朝一个独立抽取的同族图的度数混合)。对 $\hat{c}$ 我们以比例 $\eta \in [0, 1]$ 将实现计数朝一个集中随机目标混合，报告诱导的 $\ell_1(p, q)$ 。由于 MPD 仅经诱导顺序依赖于 μ ，顺序/幅度之别正是第 5 章的主题。

3.4 一致性与鲁棒性

对一个消费预测的算法，**一致性**是其在完美建议下的比值，**鲁棒性**是其在对抗建议下的最坏比值。一个有用的算法应既一致、又从不 (大幅) 低于 ρ_{base} ；二者之间的张力是第 6 章与 10.2 节展望的主题。

3.5 实验框架

框架是一个小型、依赖轻量的 Python 代码库 (NumPy、SciPy、NetworkX)。所有随机性都来自 NumPy 的 spawn 机制得到的独立、可复现的流——默认四条流 (图、实例、Ranking、Jaillet-Lu)，并为预测生成与扰动派生额外的流，因此新增一个算法从不扰动既有结果。我们使用**配对试验**：在一次比较中，每个算法与误差水平复用同一图、到达序列、OPT 与平局种子，因此差异可归因于预测本身。所报告的比值为试验上的均值及 95% 正态近似置信区间。全文每张图与表都由单个脚本从固定种子重生成 (附录 A)。

3.6 地基验证：复现 Borodin 等人

在框架上构建基于预测的算法之前，我们对照 Borodin、Karavasilis 与 Pankratov [5] 已发表的实验研究验证了它。这是一次**保真度检验**，而非**贡献**：其目的是确认生成器、i.i.d. 采样器、Hopcroft–Karp 最优解与算法实现能复现该文的定性发现，从而使日后的差异可归因于算法而非基础设施。我们的技术栈 (Python/NetworkX) 不同于该文 (C++/Edmonds–Karp)，故我们以**定性一致**为目标，接受小的绝对差异 (≤ 0.02)。

我们在两个随机图族上复现了核心四算法（六个贪婪/非贪婪变体）， $n = 1000$ 、 $m = n$ 、每参数值 100 次试验（与该文设定一致），单一主种子。

Erdős–Rényi (边概率 c/n ；该文图 9，部分)。扫描 c 复现了特征性的 U 形及其困难情形：SimpleGreedy 在 $c \approx 4.9$ 取最小值 0.864，复杂算法的贪婪变体在 $c \approx 5.3$ 取其最小值 ≈ 0.884 。Ranking 与 SimpleGreedy 无法区分（全部 75 个值上最大差为 0.0017——该文正因此省略 Ranking 的曲线），非贪婪变体随 c 增大单调退化（Feldman $0.987 \rightarrow 0.729$ ，Jaillet–Lu $0.985 \rightarrow 0.764$ ）。我们核对的该文五条文字论断全部成立。




图 3.1: Erdős–Rényi 复现：特征 U 形，贪心最小值在 $c \approx 4.9$ 附近，非贪婪随 c 增大退化。

随机左正则 (左度数 d ；该文图 18，部分)。图景在困难情形 $d = 5$ (SimpleGreedy 最小值 0.890) 重复出现，Ranking $\approx$ SimpleGreedy (最大差 0.005)，非贪婪随 d 增大退化，贪婪复杂变体渐近 $\approx$ SimpleGreedy。

一个跨族观察。合并两次扫描浮现出一个不平凡的事实：非贪婪的 Feldman 与 Jaillet–Lu 在两个族中收敛到同一渐近比值——分别为 0.729 与 0.764，跨族相差在 0.002 内——且都高于其最坏情况理论界 (0.670 与 0.729) $+0.06$ 与 $+0.03$ 。这暗示存在一个不同于最坏情况保证的、普适的“平均情况渐近常数”




图 3.2: 随机左正则复现: 难点在 $d = 5$, Greedy $\approx$ Ranking。

——是本文反复出现的主题（平均情况远比最坏情况温和）的一个早期具体实例，后续各章的预测误差扫描将认真探究它。

结论。框架在两个族上复现了已发表的定性发现，包括困难情形的位置以及 Greedy 与 Ranking 的近乎恒等。地基可信；第 4-9 章的贡献建立于其上。（完整的复现表与论断核对清单见附录 A。）

第四章 统一基准

在验证框架（第 3 章）之后，我们将三个算法族置于其上，确立本文的组织性发现。本章以竞争比（均值 $\pm$ 95% 置信区间）作为预测质量的函数，在三个面板中报告，各面板对应各族被设计的体制；它所提炼的四个发现（4.2 节）贯穿全文其余部分。

4.1 设计

各族消费不同的预测对象，故各以自己的扰动旋钮驱动并在并列面板中呈现（第 3 章）；共享的框架——图、OPT、置信区间方法、以及免预测地板——正是使各面板可比的东西。

实例格式与符号。每个面板都使用第 3 章的实例格式： n 个离线资源、 r 个在线请求类型、以及从类型分布独立同分布抽取的 m 个到达；本章全程取 $m = n$ ，即请求数与资源数持平。各面板仅在连接请求与资源的类型图上不同——正是这一处变化，把输入在两个预测族各自被设计的体制之间切换：

- **面板 A** ——**clvb_zipf** ($n = 1000$, 60 次试验)：资源度数服从指数为 1.0 的 Zipf 幂律——少数资源被激烈争用、多数资源少有请求可用。这种重尾分布让**度数**预测器有真实的信号可携带。
- **面板 B** ——**左正则** $d=5$ ($n = 1000$, 60 次试验)：每个到达的请求恰好连接 $d = 5$ 个均匀随机的资源，资源度数近乎均匀——第 3 章的困难情形，度数预测器几乎没有信号可携带。
- **面板 C** ——**少类型** $r=8$ ($n = 2000$, 50 次试验)：只有 $r = 8$ 个不同的请求类型，每个类型平均到达 $\approx n/r = 250$ 次——近乎完美可匹配的少类型体制，正是**直方图**建议算法被校准的场景；其测试-回退检验考察前 $k = 200$ 个到达。

因此面板 A 与 B 检验度数预测族（MPD 及其增强），面板 C 检验直方图建议族（FollowPrediction、TestAndMatch、组合器）。

共享方法。每个面板都采用**配对试验**：面板内每个算法与质量水平复用同一批图、到达序列、实现最优解（Hopcroft-Karp）与平局种子，故列间差异可完全归因于预测本身。所有随机性来自每面板一个主种子派生的四条独立流（图、实例、算法平局、预测扰动）。表项为试验均值及 95% 正态近似置信区间，全程很紧（ ± 0.001 - 0.003 ）。质量列实例化 3.3 节的误差模型——度数面板：**完美**（真实实现度数）、**含噪**（强度 $\frac{1}{2}$ 的随机翻转）、**对抗**（逆序反射）、**垃圾**（独立随机 μ , $\equiv$ Ranking）；建议面板：真实直方图以 $\eta \in \{0, 0.3, 0.6, 1.0\}$ 朝一个集中随机目标混合（完美/轻度/严重/垃圾）。表 4.1 将各面板的比值与其柱状图并排呈现；发现见 4.2 节。

面板 A—— <i>clwb_zipf</i>	完美	含噪	对抗	垃圾
Ranking (地板)	0.948	—	—	—
MinDegree (预言机)	0.996	—	—	—
MPD	0.989	0.956	0.908	0.946
Feldman(MPD)	0.981	0.979	0.976	0.978
JailletLu(MPD)	0.977	0.976	0.974	0.975
Feldman (基础版)	0.887	—	—	—
JailletLu (基础版)	0.901	—	—	—

面板 B——左正则 $d=5$	完美	含噪	对抗	垃圾
Greedy = Ranking (地板)	0.890	—	—	—
MinDegree (预言机)	0.966	—	—	—
MPD	0.932	0.906	0.854	0.888
Feldman(MPD)	0.906	0.903	0.896	0.900
JailletLu(MPD)	0.903	0.902	0.898	0.901
Feldman (基础版)	0.758	—	—	—
JailletLu (基础版)	0.789	—	—	—

面板 C——少类型 $r=8$	完美	轻度	严重	垃圾
Ranking (地板)	0.990	—	—	—
MinDegree (预言机)	0.999	—	—	—
FollowPrediction	1.000	0.832	0.679	0.472
TestAndMatch (Choo)	1.000	0.984	0.989	0.990
TestAndMatch (BEM)	0.998	0.988	0.988	0.968
Combiner (基准)	0.990	0.990	0.990	0.990




表 4.1: 统一基准。各面板的竞争比（配对试验均值；所有 95% 置信区间 ≤ 0.003 ）与其柱状图并排（误差棒：95% CI；虚线：免预测地板；点线：预言机天花板）。加粗为跌破地板的项。

4.2 四个发现

(F1) 鲁棒性是工程出来的，而非免费的：裸跟随者跌破地板。两个无防护的预测跟随者一旦预测为对抗或垃圾，都会跌到免预测 Ranking 地板之下：MPD 落到 $0.908 < 0.948$ （面板 A）与 $0.854 < 0.890$ （面板 B），FollowPrediction 崩到 $0.472 \ll 0.990$ （面板 C）。无防护地使用二者中的任何一个，都严格劣于不用预测。表中每个鲁棒算法——增强版、TestAndMatch、组合器——都在构造上避免了这一点。

(F2) 两种不同的鲁棒机制，形状不同。结构式鲁棒（Feldman(MPD)、JailletLu(MPD)）：最坏情况最优的基匹配承担负载，预测仅打破平局，故性能几乎平坦——Feldman(MPD) 从完美到对抗仅移动

0.981 $\rightarrow$ 0.976（面板 A）。它不会崩，但也封顶了上升空间（永远够不到 0.996 的预言机）。自适应鲁棒（TestAndMatch）：在亚线性前缀上检验，再提交——建议好时抓住上升空间（Choo 1.000），建议坏时守住地板（0.990）。在面板 C 上，它是唯一在两端都处于上包络的算法。两种机制以相反的方式用一致性换鲁棒性；图 4.1 把每个算法画在一致性-鲁棒性平面上，两种机制相反的取舍——以及 TestAndMatch 之外通向理想右上角的空白区域——一目了然。




图 4.1: 一致性-鲁棒性平面（数据即表 4.1）；虚线为免预测地板，点线为预言机天花板。TestAndMatch 最接近理想的右上角。

(F3) 平均情况输入上一致性上升空间很小；差异全在坏建议一侧。在少类型上，免预测 Ranking 已达 0.990，用真实度数的 MPD 达 0.999——好建议侧任何添益都不足 0.01。面板 C 中每个宽大的裂口都是下行裂口。这是本文论点的一图缩影；第 6 章表明为何没有负担得起的检验能逃脱它，结论章的展望（10.2 节）解释它为何是被迫的。

(F4) 增强救活了结构性薄弱的基算法。Feldman 与 Jaillet-Lu 为最坏情况比值而调，在这些平均情况输入上是最弱的免预测项（面板 B: 0.758 / 0.789，低于 Greedy 的 0.890）；MPD 增强将它们抬到 ≈ 0.90 。预测对为最坏情况设计的算法所做的，多于对贪婪所做的——这一配对只有在统一表下才可见。

4.3 本章小结

综合来看，F1-F4 表明：在平均情况匹配上，免预测基线本已近乎最优，无防护地跟随预测是不安全的，而成熟算法的价值是由两种机制之一提供的下行保护。第 5-7 章锐化各部分——什么支配那（微小的）损失、自适应检验的代价几何、以及该图景在真实数据上是否成立——结论章的展望（10.2 节）则解释这堵墙为何是被迫而非偶然。

第五章 什么支配损失：顺序误差与 ACI 的界

第 4 章表明，在平均情况输入上，度数预测算法的损失很小。本章追问是什么支配该损失。MinPredictedDegree 按预测度数升序匹配，故它仅通过 μ 在资源上诱导的顺序依赖于预测器：诱导相同顺序的两个预测器产生相同的匹配，而 μ 的单调重缩放毫无影响。因此正确的问题不是“误差有多大”，而是“哪个顺序误差支配损失、以及有多紧”。回答它需谨慎，因为“支配 MPD 的是顺序而非幅度”这一确定性事实已是定理，我们对何为已有、何为我们的贡献保持明确。

5.1 已知的部分 (ACI)

Aamand、Chen 与 Indyk [11, 附录 D] 证明：在 CLV-B 模型上，MinPredictedDegree 相对真实期望度数的匹配损失至多为 $n - \text{LIS}(p[\mu])$ ，其中 $p[\mu]$ 是按 μ 排序的真实权重，LIS 为最长非降子序列——一个纯顺序量。特别地，一个单调（保序）预测器使 $p[\mu]$ 已排好序，故 $n - \text{LIS} = 0$ ，损失为零。因此，顺序依赖性与单调偏置的零效应是 ACI 的结果，而非我们的；我们的 `systematic_bias` 误差模型（单调重缩放）在构造上 $\text{Kendall-}\tau \equiv 0$ ，且相应地在整个基准中使 MPD 的比值完全不变（第 4 章）——这是对 ACI 陈述的经验印证，而非新发现。

5.2 我们的刻画

我们跨强度扫描四种结构化误差模型，并在同一批实例上逐模型、逐水平记录三个量：实际 MPD 匹配损失、ACI 的 $n - \text{LIS}$ 、以及归一化 $\text{Kendall-}\tau$ 顺序误差（图 5.1； $n = 1000$ ，Zipf 指数 1.0，40 次试验）。

(i) **ACI 的 $n - \text{LIS}$ 界正确但非常松。**实际损失在每一点都远低于该界——约松 $16\times$ （对抗）到 $75\times$ （分布漂移）；图 5.1(a) 中所有点都紧贴坐标轴。

(ii) **$n - \text{LIS}$ 饱和，无法区分误差结构。**对每种非平凡误差，它都被钉在其最大值附近（ $n = 1000$ 时 $\approx 610\text{--}673$ ），尽管各模型的真实损失相差五倍（漂移 8.1、随机翻转 21.6、对抗 41.7）。作为一个几乎总是 $\approx n$ 的界，它几乎不携带“哪个预测更有害”的信息。

(iii) **$\text{Kendall-}\tau$ 是支配性的顺序度量，各模型塌缩到它之上。**对 $\text{Kendall-}\tau$ 作图（图 5.1(b)），四个




图 5.1: 顺序误差支配损失: 实际损失远低于 ACI 的 $n-LIS$ 界 (a), 且四种误差模型都塌缩到 Kendall- τ 上 (b)。

模型落在一条递增曲线上——损失随 τ 上升（漂移、随机翻转、对抗为 $0.29 \rightarrow 0.50 \rightarrow 1.0$ ，对应损失 $8.1 \rightarrow 21.6 \rightarrow 41.7$ ），**systematic_bias** 钉在 $\tau = 0$ 、零损失。预测损失并统一各误差结构的量，是 Kendall- τ 顺序距离，而饱和的 $n-LIS$ 无法分辨它。

5.3 本章小结

我们不声称支配 MPD 的是顺序而非幅度——ACI 的附录 D 已确立这一点，连同单调偏置的零效应。我们所添加的是一个精确的经验刻画：ACI 的 $n-LIS$ 界松了一到近两个数量级且会饱和，而 Kendall- τ 预测实际损失并将四种误差结构统一起来。这既锐化了理论的实践内涵，也为在真实数据上对预测器施压时所用的单一顺序误差轴提供了依据（第 7 章）。

第六章 深入研究测试-回退

测试-回退算法是第 4 章的自适应鲁棒机制。本章给出对它们的首个实证研究：它们所达到的鲁棒性包络（6.1 节）、接受阈值的一个反直觉失效（6.2 节）、其重校准以及重校准所暴露的分辨率极限（6.3 节）——该极限在整个难度范围上持续成立，并为 10.2 节的理论展望提供经验锚点——以及对动态组合器的基准评测（6.4 节），后者解释了先测试再一次性提交的结构。全程中， ℓ_1 检验是原作者自己也退回使用的经验代理（第 3 章）。

6.1 鲁棒性包络

在少类型实例上扫描建议误差 $\ell_1(p, q)$ ($n = 2000$, $r = 8$, 前缀 $k = 200$, 40 次试验；图 6.1)，FollowPrediction 从完美建议的 1.000 线性退化到 $\ell_1 \approx 1.1$ 处的 0.453——远低于免预测地板 (≈ 0.99)。TestAndMatch 则稳在上包络：建议好时抓住收益，建议坏时其前缀检验拒绝它并回退到 Ranking，从不崩溃（BEM $0.998 \rightarrow 0.969$ ；Choo $1.000 \rightarrow 0.991$ ）。这是第 4 章结构式鲁棒的自适应对应物。




图 6.1: 鲁棒性包络：随建议误差增大，盲目 FollowPrediction 跌破免预测地板；TestAndMatch 保持在上包络。

6.2 一个在平均情况输入上过于宽松的阈值

在边界建议 ($\eta = 0.15$, 真实 $\ell_1 \approx 0.16$) —— 检验最吃力之处 (图 6.2) —— 处扫描前缀 (检验) 规模 k , 一个更大、更准确的检验反而做出更差的决策: 随 k 从 25 增到 800, 比值下降 $0.992 \rightarrow 0.956$, 误判率上升 $0.00 \rightarrow 0.60$ 。机制在于: Choo/BEM 阈值 τ 是按最坏情况基线 $\beta \approx 0.696$ 校准的, 但在这些实例上基线为 ≈ 0.99 (F3), 故经验盈亏平衡点位于 $\ell_1 \approx 0$, 远低于 τ 。一个小而含噪的前缀高估 ℓ_1 并意外拒绝边界建议 (安全落在地板上); 一个大而准确的前缀正确测得 $\ell_1 \approx 0.16 < \tau$, 从而接受了最坏情况阈值判定为可接受的轻度坏建议——表现低于基线。在强基线输入上最坏情况阈值过于宽松, 而更准确的检验只是更忠实地跟随它。




图 6.2: 边界建议下的检验代价: 在最坏情况校准的阈值下, 更大、更准的前缀检验反而做出更差的决策。

6.3 重校准, 及其暴露的分辨率极限

将 τ 重校准到测得的基线 $\hat{\beta}$ 可消除该病理 (图 6.3): 在边界建议处, 最坏情况阈值的误判随前缀增长从 0.03 攀到 1.00、比值降到 0.920, 而重校准阈值在每个前缀规模上都保持误判 0.00、比值 ≈ 0.986 。但重校准暴露出一个更深的极限。在完美建议下, 最坏情况阈值得 1.000, 而重校准的仅得 0.987: 重校准的 $\tau \approx 2(1 - \hat{\beta}) \approx 0.028$ 小于经验 ℓ_1 估计器自身的噪声底 ($\approx 0.05-0.13$), 故它永远无法自信地接受——它拒绝一切 (包括完美建议), 总是回退到基线。一言以蔽之:

在强基线实例上, 没有任何实用的经验 ℓ_1 阈值能既抓住一致性上升空间又保持安全: 上升空间很小、且位于估计器的分辨率之下。最坏情况阈值过度接受; 重校准阈值过度拒绝; 更好的检验只是更忠实地跟随其中之一。

图 6.4 把这一发现从单个阈值推广到整个难度范围。扫描类型数——设定基线强度的旋钮——随着基线变弱, 完美建议的潜在上升空间增大; 但一个亚线性前缀检验能安全捕获的上升空间始终钉在零附近: 凡上升空间存在之处, 经验检验的分辨率 (噪声底) 都远高于盈亏平衡边际。因此本章的墙并非一




图 6.3: 重校准消除阈值病理: 误判率在每个前缀规模都保持为零, 而最坏情况阈值下攀向 1.0。

个校准不当的阈值。上升空间与检验分辨率同进退——结论章的展望(10.2 节)将给这一耦合一个定量形式: 做出决策所需的前缀规模按赌注的平方反比增长。




图 6.4: 检验之墙的境界图: 随基线变弱(左), 完美建议的潜在上升空间增大, 但亚线性检验能安全捕获的上升空间始终接近零——凡上升空间存在之处, 经验检验的分辨率都远高于盈亏平衡边际。

6.4 动态组合器被支配, 并揭示为何匹配需要先测试再提交

最后我们对 Chłędowski 式动态组合器做基准评测, 以映衬测试-回退的一次性提交结构。在其稳健调参下, 组合器恰好落在地板上(少类型上所有建议质量下均为 0.990): 它从不崩溃, 但一点一致性上升空间也抓不到, 严格被 TestAndMatch 支配。更有启发的是, 一个急切、中途切换专家的组合器揭示了一个不可逆问题特有的惩罚: 在完美建议下, 急切切换得 0.927——低于纯跟随者(1.000)和纯基线

(0.958; 见 `tests/test_combiner_small.py`) 二者——因为中途从 Ranking 切到模仿 (mimic) 模式会使已提交的匹配落入一个 **不兼容的混合态**。在不可逆问题中, 跟随/回退的决策必须在大批承诺之前做出, 这正是 Choo/BEM 在前缀上检验、然后**提交**、而非像缓存式组合器那样动态切换的原因。对缓存而言是廉价保险的动态组合器, 无法干净地移植到匹配上。

6.5 本章小结

测试-回退提供了 6.1 节的自适应鲁棒包络, 但其接受/拒绝决策在强基线输入上有根本限制: 没有经验 ℓ_1 阈值能既抓上升又保安全 (6.3 节), 且动态切换被“先测试再提交”支配 (6.4 节)。6.3 节的分辨率极限——及其在整个难度范围上的持续成立 (图 6.4) ——是 10.2 节理论展望的经验锚点。

第七章 外部效应

第 4-6 章使用合成图与一个合成误差旋钮。这一图景是真实的吗？我们从三个方面施压：真实请求 trace 上一个真实、廉价的预测器（7.1 节）；六个真实世界图（7.2 节）；以及学习预测器是否会改变什么（7.3 节）。

7.1 一个真实、廉价的预测器

我们用最廉价的现实预测器替换合成旋钮：上一窗口的历史统计。真实的 Wikipedia 每日页面浏览给出一个直播日（真值）与若干更早的日（1、7 或 30 天陈旧的预测），故误差是真实的时间漂移；我们将该 trace 映射到一个固定的服务拓扑，并通过度数路线（MPD）消费该预测（图 7.1）。三个事实浮现。第一，**成本前提不成立**：该预测器是一次线性时间的计数（0.108 毫秒——约为计算一次 OPT 成本的 2%），而非机器学习推理。第二，**收益真实、部分、且从不有害**：一个陈旧预测捕获 27%–68% 的可达预言机缺口（随陈旧度下降），且**始终高于免预测基线**（0.938–0.957 vs 0.923–0.925，即便在 30 天时）。第三，原因在于：**拓扑聚合使廉价预测器保序**——诱导度数预测器的顺序误差仅为 $\text{Kendall-}\tau \approx 0.19\text{--}0.32$ ，约为原始直方图（0.38–0.49）的一半——而由于 MPD 仅依赖顺序（第 5 章），聚合后的度数路线在真实漂移下存活下来。将**同一预测通过原始直方图消费**则是灾难性的：盲从的 FollowPrediction 崩到 $0.68 \rightarrow 0.36$ ，远低于 ≈ 0.92 的基线——这正是第 4 章与第 6 章的鲁棒算法的用武之地。




图 7.1: 真实的廉价预测器 (Wikipedia trace): 聚合使顺序误差减半 (a), 度数路径经受住陈旧化 (b); 盲目跟随直方图则衰减。

7.2 六个真实世界图

我们在六个 Network Repository 图（两个 Facebook 社交、两个 *C. elegans* 生物、两个经济投入产出）上，跨相同的质量列、带 95% 置信区间，重跑第 4 章的度数预测算法阵容（图 7.2）。两个承重发现是普适的。**F1 在全部六个图上成立**：喂给对抗预测器的裸 MPD 在每个图上都跌破 Ranking 地板——差 0.07（Caltech36）到 0.11（CE-PG）。**F3 普适且印证其自身逻辑**：一致性上升空间处处很小（均值 +0.049；范围 +0.022–+0.077），且恰恰在基线最强处最小——两个稠密经济图，其 Ranking 已达 0.965/0.977，给出最小的上升空间。

结构式鲁棒发现 **F2 在全部六个图上定性成立**（增强版始终比裸 MPD 对预测质量更不敏感），并在四个社交/生物图上**严格成立**（谱宽为 MPD 的 0.22–0.29 $\times$ ）；在两个稠密经济图上保护只是**部分的**——增强缓冲了对抗下的跌落（0.939 vs 裸 MPD 的 0.893），但清不掉异常高的 0.965 地板，落到其下 ≈ 0.03 。这个经济图边界具有启发性而非失败：那些图太稠密，匹配近乎平凡（Ranking ≈ 0.97 , MinDegree = 1.00），故既无上升空间可抓（F3）、也无多少下行需保护。最后，F4 在此**极为显著**：为最坏情况设计的 Feldman/Jaillet-Lu 在经济图上是**最弱的免预测项**（0.73–0.77），而增强将它们抬到 0.99——一次 +0.26 的救援。




图 7.2: 六个真实图上的 F1–F3: 裸 MPD (红) 处处跌破 Ranking 地板; 结构式增强 (绿/蓝) 保持平坦。

7.3 学习预测器是否有帮助?

由于 MPD 仅经顺序消费预测器（第 5 章），人们或许会想用顺序损失（rank loss）而非回归来训练它。我们对此做了检验，报告一个诚实的负结果。用**刻意发散**的合成特征，rank 训练锐利地击败回归 ($0.989 \approx$ 预言机 vs 0.974 ，其回归误差更差但顺序更好)；但该优势被特征发散度与图难度双重门控（峰值仅 +1.3%），且 **决定性地，在真实时序特征上它消失了**——rank 训练与回归训练的预测器产生**相同**的顺序（Kendall- τ 0.126 vs 0.126 ）与相同的匹配比值。驱动顺序感知训练的解离是**人为特征**的属性，而非现实特征的属性。（这一探索的更完整叙述见第 8 章。）这一教训强化了本文论点：一旦预测器保序——而廉价的历史计数本已如此（7.1 节）——在平均情况匹配上，无论更好的算法还是更好训练的预测器都买不到多少。

7.4 本章小结

在真实预测器、真实图与一个学习预测器上，同一堵墙依然矗立：免预测基线近乎最优、无防护跟随不安全、预测买到的是下行保护而非性能。在我们所能触及的每一种设置上都从经验上确立了这堵墙之后，第 8 章报告试图越过它的方向，结论章的展望（10.2 节）解释它为何是被迫的。

第八章 探索方向与负结果

实验各章（第 4–7 章）确立了一堵墙：在平均情况匹配上，免预测基线近乎最优，故预测是鲁棒性保险而非性能杠杆。在把这堵墙当作定论之前，我们追求了三个各自**试图越过它**的方向——学习预测器以榨取更多性能（8.1 节）、寻找一个预测真正有帮助的服务场景（8.2 节）、以及让一次系统的文献综述为我们指出最高价值的贡献（8.3 节）。三者都返回了同一个答案，它们的收敛正是使我们怀疑这堵墙是被迫的原因。本章诚实地报告它们，包括负结果，因为它们是证据的一部分，且排除有雄心的替代方案本身就是一个结果。

8.1 学习为预测器排序（一个负结果）

第 5 章表明 MPD 仅通过其诱导的**顺序**消费预测器。这提示了一个具体的改进途径：不再训练预测器最小化其对真实度数的**回归误差**（标准的“先预测再优化”目标），而是用一个**顺序感知损失**——成对 rank 损失——训练它，使其优化算法实际使用的量。我们分三步考察。

M0——机制存在。用刻意发散的合成特征（一个特征承载幅度、另一个承载顺序），一个 rank 训练的线性预测器在决策度量上锐利地击败回归训练者：匹配比值 0.989（基本上是预言机）对 0.974，而 rank 训练的预测器对真值的回归误差**更差**（MSE 87.6 vs 33.4），顺序却更好（Kendall- τ 0.058 vs 0.255）。这一解离是真实的：**更差的拟合给出更好的决策**，印证了当决策重要时回归是错误的训练目标。

M1——但优势被双重门控，且很小。扫描特征发散度与图难度，rank 优势在特征不诱导顺序/幅度冲突时为零，在基线本已最优的容易实例上也为零（又是那堵墙）。它在合成图上峰值仅 +1.3%；一个更有利的表述是 **gap-capture**：rank 训练基本上恢复整个预言机缺口，而回归留下约 30% 未实现——但缺口本身很小。

M3——且在真实特征上消失。决定性的检验使用来自真实服务 trace 的真实时序特征（各资源在此前若干窗口的引用计数）来预测下一窗口。此处 rank 训练与回归训练的预测器产生**相同**的顺序（Kendall- τ 0.126 vs 0.126）与相同的匹配比值，在所试的每一种拓扑与滞后配置下皆然。驱动 rank 训练的顺序/幅度发散是**人为**特征的属性；现实的滞后计数特征是同一流行度的共线含噪估计，故回归本已把顺序学得和排序一样好。

裁决。用决策对齐损失学习预测器不构成一个独立贡献：其取胜需要一个现实中不出现的特征发散，且即便出现，收益也受制于那（微小的）基线到预言机缺口。该结果作为一个**强化核心发现**的负结果被并




图 8.1: M0: 发散特征下, rank 训练在匹配比值上胜过回归 (左), 尽管回归拟合更差 (右)。




图 8.2: M3 (Azure trace, 真实时序特征): rank 训练与 MSE 训练的预测器不可区分——驱动 rank 训练的人造发散并不出现。

入本文——一旦预测器保序（廉价历史计数本已如此，第 7 章），在平均情况匹配上无论更好的算法还是更好训练的预测器都买不到多少。

8.2 用一个带预测的结果救援服务应用（一个负探针）

服务案例研究（第 9 章）复现了已确立的系统结论，因此被呈现为案例研究而非新意声明。我们追问是否有一个 **新的**、可行动的带预测结果能救援它。障碍又是那堵墙：我们所试的每个服务变体都优化吞吐（goodput），而吞吐是宽容的——过载下反应式路由填满容量的方式与最优相同，故预测毫无添益。若存在出路，必是一个反应式基线在其上确实远离最优的不同目标。

我们探测了最有希望的候选：一个 **SLO/尾部目标**——在突发、非平稳负载下保护一类紧 SLO 请求不被丢弃——恰恰是反应式策略因缺乏前瞻可能失败的体制。用一个事件驱动模拟器，我们将非预测策略（静态容量预留；一个基于观测近期负载做预留的反应式自适应策略）与一个基于**实际未来**突发做预留的 **clairvoyant 预言机**对比。在所扫的每个体制——过载水平、均匀 vs 突发紧 SLO 需求——最佳非预测策略都在 $\leq 3\%$ 内匹配 clairvoyant 预言机；在中度体制下，一个仅预留一个槽位的平凡静态预留甚至直接反超预言机。两个原因，都对扫描稳健：保护一个紧 SLO 少数只需一点静态余量、无需预测；且突发足够持续，使得对观测负载做反应几乎和预测它一样好。




图 8.3: 服务 SLO 探针：非预测策略在几个百分点内匹配 clairvoyant 预言机——前瞻无济于事。

裁决。尾部目标也是宽容的——继吞吐（第 4-7 章）与预测器学习（8.1 节）之后，这是墙的第三张脸。我们没有找到前瞻有帮助的自然体制，故服务仍是案例研究。一个能打破这堵墙的体制（一个基线远离最优的非平稳或对抗目标）正是本文作为未来工作所框定的那类设置。

8.3 一次重定向了工作的文献综述

判定我们的哪些发现真正新颖——并值得发展——需要一次系统的 prior-art 综述而非直觉。我们进行了一次大规模、多源、对抗验证的文献检索（记录于 docs/LITERATURE_REVIEW.md），它返回了诚实、有时令人沮丧的裁决。它确认统一实验基准与对测试-回退的实证研究无人占据、值得领衔；顺序误差发现被 ACI 的附录 D 部分预占，须重构为紧度/度量刻画而非发现（第 5 章）；服务结论大多是已确立系统事实的重新推导，故应降格为案例研究（8.2 节、第 9 章）。第二次针对理论问题的聚焦 prior-art 检查确认此前无工作量化前缀检验在强基线实例上的代价，同时标出任何此类结果都须防范的风险（Choo 等人构造性的基线耦合）——二者都是 10.2 节展望及其所指后续理论工作的输入。

这次综述本身是此处所报告研究过程的一部分：它把一堆无差别的发现变成了有优先级的贡献，将精力从低价值的细化（带权价值变体、更多基线比较）重定向到那个理论问题，并贯彻了全文的诚实护栏。

8.4 综合：负结果指向同一堵墙

三次探索指向同一方向。更好训练的预测器在真实特征上无帮助（8.1 节）；带预测的视角即便在尾部目标上也无法救援服务（8.2 节）；文献综述确认没有唾手可得的性能胜利（8.3 节）。连同第 4-7 章的吞吐墙，它们表明该现象不限于单一目标、单一算法或单一数据集——在我们所推的每个方向上都反复出现。这种经验发现的稳健性正是暗示它可能是被迫而非偶然的东西——这正是结论章展望（10.2 节）所接手的问题，也是筹备中的后续理论工作所要完整回答的问题。

第九章 应用案例研究：AI 推理服务

本文的抽象并不局限于经典的匹配市场；它可实例化一个当代系统问题。本章将 AI 推理服务系统中的请求路由建模为在线匹配，并表明该框架复现了该领域已确立的结论。它被刻意地呈现为案例研究，而非新意声明——下文的系统事实是已知的，带预测的措辞只是对它们的重新标注（这一决定由第 8 章的文献综述与 9.2 节概述的负探针所证成）。

9.1 服务实例化

我们将服务映射为在线 b -匹配：离线资源是模型副本或缓存分片，各有一个容量 c （本窗口最多并发服务 c 个请求，故为 b -匹配而非 1-匹配）；到达是从一个非均匀、突发的流量分布中抽取的请求；一条边是一种能力或缓存亲和性；而 **goodput**——被服务请求的比例——是相对 b -匹配最优的竞争比。我们在三个真实 trace（Wikipedia 页面浏览、一个 Azure LLM 推理 trace、以及 Mooncake 前缀缓存 trace [20]）上、跨四个服务关注点实例化它。




图 9.1: 容量作为鲁棒性：盲目跟随预测使 goodput 崩塌——容量充裕 ($c = 8$) 时更深——而自适应检验保持平坦。

容量作为鲁棒性（图 9.1）。增大容量 c 会平滑坏预测的影响：一个容量感知的基线保持安全，而盲目信任一个流量预测则随容量增大而进一步退化。因此容量是算法鲁棒性的一个替代品——是鲁棒性保

险论点的系统对应物。




图 9.2: 动态服务时间下实时负载胜过陈旧预测；自适应检验挽回大部分差距。

预测 vs 实时负载 (图 9.2)。在动态服务时间下（请求占据一个槽位一段真实时长、按事件逐一释放），一个实时负载信号胜过一个陈旧的流量预测——当预测老化时，一个反应式负载均衡器胜过一个跟随预测的路由器。




图 9.3: 缓存亲和反转 (Mooncake trace): 对 KV 缓存复用, 稳定放置胜过反应式路由。

缓存亲和路由 (图 9.3)。对前缀缓存感知的路由, 一个稳定的亲和路由器胜过一个反应式的——与流量预测的情形相反, 因为缓存局部性奖励持久性 [21]。

这些各自都干净地复现了一个已确立的系统结论, 表明该框架忠实地实例化了该问题。

9.2 一次寻找真正新结果的探针，及其负结果

由于文献暗示带预测的视角或许能在某个尾部目标上给出一个**新的**、可行动的服务结果，我们对其做了探测（完整叙述见第 8 章）。在一个 SLO/尾部目标——在突发负载下保护一类紧 SLO 请求——上，一个非预测策略（静态余量，或基于观测负载的反应式自适应预留）在所扫的每个体制中都在 $\leq 3\%$ 内匹配一个 clairvoyant 预言机；在中度体制下，一个仅预留一个槽位的平凡静态预留甚至反超预言机。两个原因，都稳健：保护一个紧 SLO 少数只需一点静态余量、无需预测；且突发足够持续，使对观测负载做反应几乎和预测它一样好。尾部目标也是宽容的——继吞吐（第 4-7 章）与预测器学习（第 8 章）之后，这是本文那堵墙的第三张脸。我们没有找到前瞻有帮助的自然体制，故服务仍是案例研究。

9.3 本章小结

服务实例化表明该框架能触及一个真实的系统问题并复现其已确立的结论——容量作为鲁棒性替代、实时负载胜过陈旧预测、稳定性利于缓存局部性——且即便一个尾部目标也未开启一个真正的带预测胜利。该应用是本文的一个忠实案例研究，而非一个独立贡献。

第十章 结论与未来工作

10.1 总结

本文研究了面向在线二部匹配的学习增强算法：先构建一个共同的实验基础，再解释它所揭示的东西。在同一套框架上——对照 Borodin 等人已发表的研究验证（第 3 章）——我们比较了免预测基线、Min-PredictedDegree 及其增强、以及测试-回退算法，跨越合成图、六个真实世界图与真实请求 trace（第 4–7 章）。在每一种设置上都浮现同一图景：在平均情况输入上免预测基线本已近乎最优，故一个好预测的**一致性**上升空间很小；无防护地跟随预测在坏预测下会崩到**低于**基线；而成熟算法的价值是下行保护，由结构式或自适应式鲁棒机制以不同取舍提供。我们锐化了子问题——那（微小的）损失由 Kendall- τ 顺序误差而非幅度支配（第 5 章，将顺序依赖性本身归功于 ACI 的在先结果），以及自适应检验有一个阈值校准病理与一个分辨率极限（第 6 章）——并诚实地报告了那些**未奏效**的方向：学习预测器以榨取更多性能，以及寻找一个预测真正有帮助的服务场景（第 8 章）。

这堵反复出现的墙引出一个显然的问题：它是我们所选输入的偶然，还是被迫的？下一节以展望的形式给出我们的回答。统一全文的一句话是：在平均情况的在线匹配上，预测是鲁棒性保险而非性能杠杆——而其上升空间小于“判定预测是否可信”所需付出的代价。

10.2 理论展望：检验建议的代价

实验表明，没有任何**实用的**接受阈值能安全地捕获上升空间（6.3 节，图 6.4）。本节在不声称完整定理的前提下，勾勒为什么在这堵墙矗立的输入上，**任何**决策规则都无法逃脱。其中一个组件在此处给出证明；其余是对本文自身实验的定量解读，其完整的形式化发展被有意留给筹备中的后续工作。

一个权衡不等式。设 G 与 Bd 是共享**同一**建议的两个实例分布，跟随建议相对免预测基线，在 G 下获益 δ 、在 Bd 下受损 Δ ；记 γ_k 为二者长度为 k 的前缀分布之间的全变差距离。则每个测试-回退算法——无论其在前缀上用**任何**可测规则做决策——都满足

$$(1 - \eta_c) \leq \eta_r + \gamma_k + o(1),$$

其中 η_c 是它在 G 下放弃的上升空间比例， η_r 是它在 Bd 下以 Δ 为单位的鲁棒性损失。

证明是一个简短的条件化论证：捕获上升空间迫使算法在 G 下以高概率跟随；鲁棒性迫使它在 Bd 下回退；而前缀的任何函数都无法在两个统计上 γ_k -接近的前缀分布上表现不同。该不等式把“既一致又鲁棒”转化为一个**样本复杂度**问题：前缀要多长，才能把值得跟随的建议与应当拒绝的建议区分开？

在产生图 6.4 的稀缺资源实例上，答案是一条**预算-赌注定律**：做出决策需要 $k^* = \tilde{\Theta}(\theta/\delta^2)$ 的前缀——赌注 δ （好建议相对基线的收益）的平方反比、乘以争用率 θ ——且该预算是可达的：一个简单的**方向性统计量**（前缀到达与建议的预测相符多、还是相悖多？）即可实现。而赌注又被基线松弛封顶： $\delta \leq 2\varepsilon(1-\rho_{\text{base}})$ 。代入可得：在强基线实例上，所需前缀超过整个实例——任何低于 $\Theta(\sqrt{(1-\rho_{\text{base}})/n})$ 的上升空间，都无法被任何规则在任何前缀长度 $k \leq n$ 下安全捕获。在第 4 章的参数（ $\rho_{\text{base}} \approx 0.99$ 、 $n = 2000$ ）下该阈值 ≈ 0.004 ，而我们测得的上升空间恰在此量级（F3）：经验之墙正处于该定律所辖的体制。这就是图 6.4 的定量读法：潜在上升空间与可捕获上升空间随基线变强而分离，因为赌注缩小的速度快于检验分辨率改善的速度。

两条诚实的注记框定本展望的范围。其一，预算定律是双向的：赌注大（基线弱）之处，方向性统计量很便宜，跟随好建议是容易的——这堵墙是关于强基线、平均情况输入的陈述，而非关于检验本身。特别地，一个诱人的更强猜想——**容差分布检验**（2.5 节）近线性的样本代价会直接封死一切亚线性规则——是错误的：它恰被同一个方向性统计量反驳，而 6.3 节 ℓ_1 阈值的失明是“检验距离而非收益”的性质。其二，本文在此仅声称上面陈述的不等式与对自身实验的定量解读；双侧定律、其证明及其确切范围是后续工作的主题。

10.3 局限

- **输入模型**。我们在 known-i.i.d. 模型下工作。由于 $\text{Known-I.I.D.} \leq \text{Random-Order}$ 在难度上成立，算法的保证可以沿用，但我们的经验之墙是一个**平均情况**陈述；我们不为对抗到达序声称它。
- **检验模型**。遵循原作者，测试-回退实验使用一个经验 ℓ_1 代理来替代（未实现的）分布检验器；10.2 节解释了该代理的失明是结构性的，而非实现产物。
- **预测对象异质性**。度数预测族与直方图预测族并不映射到每个图上，故我们在并列面板而非同一张表中报告。
- **数据广度**。每种真实模态由一个 trace 检验。
- **理论范围**。本文有意将其理论限定于 10.2 节的展望——一条已证明的权衡不等式加上对实验的定量解读。完整的预算-赌注定律是筹备中的后续工作；除该不等式外，本文不声称任何定理。

10.4 未来工作

本文**框定**而非**解决**了预测可能真正帮助在线匹配的那些设置，它们是自然的下一步方向。

- **超越平均情况输入**。这堵墙是平均情况现象。对抗或非平稳到达序（其中免预测基线可证远离最优）正是预测应携带真实价值之处——也是本文这堵墙的一个**正向**对应结果可能被证明之处。

- **超越吞吐。**基线并不近乎最优的目标——尾部延迟、逐类型公平、迁移或重算成本——或许允许 goodput 目标所排除的真正带预测收益；我们的服务 SLO 探针（第 8 章）关闭了最简单的此类尝试，但未关闭整个空间。
- **完成理论。**完成后续的预算-赌注发展——锋利的双侧定律、作为其匹配上界的方向性统计量、及其确切范围（可分解族；非可分解族能否推高预算是开放的）——将把 10.2 节的展望变成一个紧刻画。
- **诚实地寻找更好的检验。**一个超线性或摊还的检验，或一个复用在线决策作为样本的检验，能否胜过 10.2 节的赌注平方预算，是一个开放且有实际动机的问题。

10.5 结语

预测是在线算法的一个强大工具，但本文是对其在一个被充分理解的问题上**局限**的研究。在平均情况的在线匹配上，诚实的裁决是：一个廉价、保序的预测器本已捕获了几乎全部可捕获的东西，成熟的机器以保险而非性能的方式发挥价值，且在這些輸入上，判定一个预测是否可信的代价超过了该预测本身的价值。认识预测在何处无能为力，我们希望，与知道它在何处有用同样有价值。

参考文献

- [1] R. M. Karp, U. V. Vazirani, and V. V. Vazirani. An optimal algorithm for on-line bipartite matching. *STOC*, 1990.
- [2] J. Feldman, A. Mehta, V. Mirrokni, and S. Muthukrishnan. Online stochastic matching: Beating $1-1/e$. *FOCS*, 2009.
- [3] V. H. Manshadi, S. Oveis Gharan, and A. Saberi. Online stochastic matching: Online actions based on offline statistics. *Mathematics of Operations Research*, 37 (4), pp. 559–573, 2012.
- [4] P. Jaillet and X. Lu. Online stochastic matching: New algorithms with better bounds. *Mathematics of Operations Research*, 2014.
- [5] A. Borodin, C. Karavasilis, and D. Pankratov. An experimental study of algorithms for online bipartite matching. *arXiv preprint arXiv:1808.04863*, 2018.
- [6] M. Mitzenmacher and S. Vassilvitskii. Algorithms with predictions. *Beyond the worst-case analysis of algorithms*, Cambridge University Press, pp. 646–662, 2020.
- [7] T. Lykouris and S. Vassilvitskii. Competitive caching with machine learned advice. *ICML*, 2018.
- [8] A. Wei and F. Zhang. Optimal robustness-consistency trade-offs for learning-augmented online algorithms. *NeurIPS*, 2020.
- [9] J. Chłędowski, A. Polak, B. Szabucki, and K. Żołna. Robust learning-augmented caching: An experimental study. *ICML*, 2021.
- [10] ... Yoshinaga and Y. Kawase. Analyzing the effect of prediction accuracy on the distributionally-robust competitive ratio. *arXiv preprint arXiv:2601.06813*, 2026.
- [11] A. Aamand, J. Y. Chen, and P. Indyk. (Optimal) online bipartite matching with degree information. *NeurIPS*, 2022.
- [12] D. Choo, T. Gupta, and others. Online bipartite matching with imperfect advice. *ICML*, 2024.
- [13] J. Jiao, Y. Han, and T. Weissman. Minimax estimation of the L_1 distance. *IEEE Transactions on Information Theory*, 64 (10), pp. 6672–6706, 2018.
- [14] ... Burathep, T. Erlebach, W. K. Moses, and others. Learning-augmented online bipartite matching in the random arrival order model. *SOFSEM*, 2026.
- [15] L. Paninski. A coincidence-based test for uniformity given very sparsely sampled discrete data. *IEEE Transactions on Information Theory*, 54 (10), pp. 4750–4755, 2008.

- [16] G. Valiant and P. Valiant. An automatic inequality prover and instance optimal identity testing. *SIAM Journal on Computing*, 46 (1), pp. 429–455, 2017.
- [17] G. Valiant and P. Valiant. Estimating the unseen: An $n/\log n$ -sample estimator for entropy and support size, shown optimal via new CLTs. *STOC*, 2011.
- [18] C. L. Canonne, A. Jain, G. Kamath, and J. Li. The price of tolerance in distribution testing. *COLT*, 2022.
- [19] J. E. Hopcroft and R. M. Karp. An $n^{5/2}$ algorithm for maximum matchings in bipartite graphs. *SIAM Journal on Computing*, 1973.
- [20] others. Mooncake: A KVCache-centric disaggregated architecture for LLM serving. *arXiv preprint arXiv:2407.00079*, 2024.
- [21] others. Preble: Efficient distributed prompt scheduling for LLM serving. *arXiv preprint arXiv:2407.00023*, 2024.

附录 A 复现指南

本文中每个定量结果都由单个脚本从固定种子重生成。本附录将每张图与表映射到其脚本，给出命令与运行时间，列出第 3 章推迟至此的完整 Phase-2 复现表，并记录数据来源。

A.1 环境与原则

- **技术栈**: Python 3.12; NumPy 1.26+、SciPy 1.13、NetworkX 3.3、Matplotlib (仅绘图)。
- **确定性**: 所有随机性都经 NumPy 的 `default_rng(seed).spawn(k)` 从单一主种子 (默认 0) 派生，得到独立、可复现的流 (图、实例、算法随机性、预测扰动)。结果在 NumPy 1.25 起的小版本间按位稳定 (基于 BitGenerator 的 spawn)。
- **配对试验**: 在一次比较中，每个算法与误差水平复用同一图、到达序列、OPT 与平局种子，故差异可归因于预测本身。
- **置信区间**: 试验上的 95% 正态近似半宽。
- 每个脚本写出 `results/<name>.json` (原始均值/置信区间) 与 `results/<name>.png` (图)，并打印逐步进度。

A.2 图/表 → 脚本映射

论文对象	脚本	输出	约运行时间
图 3.1 (ER U 曲线)	<code>scripts/run_er_full.py</code>	<code>results/er_full.{json,png}</code>	20 分钟
图 3.2 (左正则)	<code>scripts/run_left_regular.py</code>	<code>results/left_regular.{json,png}</code>	10 分钟
表 4.1 (统一基准)	<code>scripts/run_unified_benchmark.py</code> 再 <code>plot_unified_panels.py</code>	<code>results/unified_benchmark.{json,png}</code> 、 <code>unified_benchmark_panel{A,B,C}.png</code> 、 <code>unified_benchmark_tables.md</code>	10 秒
图 4.1 (一致性-鲁棒性平面)	<code>scripts/run_consistency_robustness.py</code>	<code>results/consistency_robustness.{json,png}</code>	1 秒
图 5.1 (顺序误差 vs ACI)	<code>scripts/run_order_vs_theory.py</code>	<code>results/order_vs_theory.{json,png}</code>	30 秒

论文对象	脚本	输出	约运行时间
图 6.1 (包络)、图 6.2 (前缀扫描)	<code>scripts/run_choo_bem.py</code>	<code>results/choo_bem_{envname, prefix}.png</code>	120 分钟
图 6.3、重校准 (6.3 节)	<code>scripts/run_recalibration.py</code>	<code>results/recalibration_*.png</code>	1.5 分钟
图 7.1 (真实预测器)	<code>scripts/run_real_predictor.py</code>	<code>results/real_predictor_*.json, png</code>	15 秒
图 7.2 (六个真实图)	<code>scripts/run_realworld_results/realworld_robustness.py</code>	<code>results/realworld_robustness_{.json, png}</code>	65 秒
图 8.1 (M0 rank vs MSE)	<code>scripts/run_rank_vs_mse.py</code>	<code>results/rank_vs_mse_mv1{.json, png}</code>	1 秒
M1 扫描 (8.1 节, 无图)	<code>scripts/run_rank_when_it_matters.py</code>	<code>results/rank_when_it_matters_{.json, png}</code>	20 秒
图 8.2 (M3 真实 trace 学习)	<code>scripts/run_rank_real_trace.py</code>	<code>results/rank_real_trace{.json, png}</code>	1 秒
图 8.3 (服务 SLO 探针)	<code>scripts/run_serving_slope.py</code>	<code>results/serving_slope_{.json, png}</code>	1 秒
图 6.4 (检验之墙边界)	<code>scripts/run_impossibility.py</code>	<code>results/impossibility_frontier_{.json, png}</code>	16 秒
图 9.1–9.3、服务 (第 9 章)	<code>scripts/run_serving*.py</code>	<code>results/serving_*.png</code> 、 <code>run_prefix_cache.py</code> <code>prefix_cache_*.png</code> 等	不一
真实图 Borodin 表 3/4 (验证)	<code>scripts/run_realworld.py</code>	<code>results/realworld.json</code>	数分钟

A.3 复现命令

```
# 从项目根目录 (matching-experiments/)
# 正确性锚点——7 个可手工验证的测试文件，全部通过：
for t in tests/test_*.py; do python3 "$t"; done
```

重生成主要结果 (快脚本):

```
python3 scripts/run_unified_benchmark.py      # 表 4.1 (数据)
python3 scripts/plot_unified_panels.py        # 表 4.1 (面板小图)
python3 scripts/run_consistency_robustness.py # 图 4.1 (重绘表 4.1)
python3 scripts/run_order_vs_theory.py        # 图 5.1
python3 scripts/run_real_predictor.py         # 图 7.1
python3 scripts/run_realworld_robustness.py   # 图 7.2
python3 scripts/run_rank_real_trace.py        # 图 8.2
python3 scripts/run_serving_slo_probe.py      # 图 8.3
python3 scripts/run_impossibility_frontier.py # 图 6.4
```

较长 (受最大流 / *Hopcroft-Karp* 限制) 的扫描:


```
python3 scripts/run_er_full.py # 图 3.1 (~20 分钟)
python3 scripts/run_left_regular.py # 图 3.2 (~10 分钟)
python3 scripts/run_choo_bem.py # 图 6.1、6.2 (~20 分钟)
```

除特别说明外所有脚本硬编码种子 0；重跑即复现所报告的数字。

A.4 完整 Phase-2 复现表（自 3.6 节推迟）

设定： $n = 1000$ 、 $m = n$ 、每参数值 100 次试验、种子 0。目标是与 Borodin 等人定性一致 (Python/NetworkX 对该文 C++/Edmonds-Karp；接受绝对差 ≤ 0.02)。

Erdős-Rényi, 选定 c 处的竞争比 (SG=SimpleGreedy, Rk=Ranking, F/J=Feldman/Jaillet-Lu, -NG/-G= 非贪婪/贪婪):

c	SG	Rk	F-NG	F-G	J-NG	J-G
0.10	0.9995	0.9994	1.0000	1.0000	0.9991	1.0000
1.90	0.9362	0.9363	0.9033	0.9637	0.9202	0.9602
4.90	0.8640	0.8655	0.7648	0.8845	0.7949	0.8854
8.90	0.9094	0.9088	0.7314	0.9123	0.7662	0.9120
14.90	0.9487	0.9486	0.7290	0.9488	0.7640	0.9483

各算法最小值 (ER): SG 0.8640 @ $c=4.9$; Rk 0.8649 @ 4.7; F-NG 0.7288 @ 13.5; F-G 0.8833 @ 5.3; J-NG 0.7616 @ 14.1; J-G 0.8839 @ 5.3。

随机左正则, 选定 d 处的竞争比:

d	SG	Rk	F-NG	F-G	J-NG	J-G
1	1.0000	1.0000	0.9845	1.0000	0.9845	1.0000
2	0.9539	0.9537	0.8769	0.9679	0.8945	0.9659
5	0.8905	0.8900	0.7595	0.9008	0.7909	0.9022
10	0.9275	0.9278	0.7317	0.9276	0.7677	0.9290
30	0.9770	0.9767	0.7308	0.9757	0.7633	0.9754

论断核对清单 (全部验证 ✓): 贪婪最小值在 $c \approx 4.9$ / $d = 5$ 附近; Ranking $\approx$ SimpleGreedy (ER 最大差 0.0017、LR 0.005——该文正因此省略 Ranking 曲线); 非贪婪变体随 c, d 增大单调退化; 贪婪复杂变体渐近 $\approx$ SimpleGreedy; $c=14.9$ 处非贪婪的排序 (J-NG 0.764 > F-NG 0.729) 与该文最坏情况界的排序一致。一个跨族观察: 非贪婪算法在两族中收敛到相同的渐近常数 (Feldman 0.729、Jaillet-Lu 0.764, 相差在 0.002 内), 高于其最坏情况界 +0.06 / +0.03——是平均情况比最坏情况温和的一个早期实例。

A.5 数据来源

真实数据本地存放于 `data/` 下（体量大；不纳入版本控制）。

- **真实图 (第 7 章、3.6 节验证)**: 六个 Network Repository 图——`socfb-Caltech36`、`socfb-Reed98`、`bio-CE-GN`、`bio-CE-PG`、`econ-beause`、`econ-mbeaflw`——为 MatrixMarket `.mtx` / 空白分隔 `.edges`，化简为简单无向图，并经随机平衡划分 (Borodin 表 3) 或复制双重覆盖 (表 4) 转为二部图。
- **Trace (第 7、8、9 章)**: 四天的 Wikipedia “每日热门文章”JSON (`data/trace/wiki/`，用作直播日 vs 1/7/30 天陈旧的预测)；Azure LLM 推理 trace (`data/trace/azure_llm/`，带时间戳的上下文/生成 token 计数)；Mooncake 会话 trace (`data/trace/mooncake/`，每请求的前缀缓存块 `hash_ids`)。

A.6 展望验证片段 (10.2 节)

10.2 节展望背后的量均经数值验证。稀缺资源构造的单 cell 常数 (每 cell 的 OPT、基线，以及优势/ ℓ_1 公式) 与精确的仿射转换律 $\mathbb{E}[\text{follow-ratio}] = \rho_{\text{perfect}} - \frac{1}{2}\ell_1(p, q)$ 由记录于项目笔记 (`docs/T1_W1_single_cell.md`、`T1_W2_W3a_closeout.md`) 的简短模拟验证到三位小数；例如在 $\theta = 0.6$ 、偏置 $|s - \frac{1}{2}| = 0.3$ 时，模拟得每 cell 优势 ± 0.119 与公式 $\pm \theta |s - \frac{1}{2}| = \pm 0.12$ 吻合。预算-赌注论断——方向性统计量在与 n 无关的固定前缀长度下的准确率、以及插入式 ℓ_1 估计在 $k \ll r$ 时的失明——由 `scripts/verify_witness_gap.py` 验证 (`docs/T1_WITNESS_GAP.md`)。这些支撑该展望；形式化发展是本文之外的后续工作。